

清华大学求真书院 / 2026 年秋季

高性能计算与人工智能应用

Math on AI

从数学走近 生成式人工智能

第零讲 课程导论

胡丕丕

概率 × 动力学 × 计算

$$p_{\theta}(x)$$

$$dX_t$$

$$\nabla_{\theta} \mathcal{L}$$



课程信息与学习目标

上课时间与地点

第 1–16 周星期四第 2 节 清华大学六教 6B404

高性能计算与人工智能应用

- ▶ 从概率分布、目标函数和采样算法三个层面理解生成模型。
- ▶ 比较不同模型的数学构造、表达约束与训练和生成成本。
- ▶ 从头实现小模型，用推导、反例和对照实验解释结果。
- ▶ 理解生成建模与世界模型、强化学习、推理、智能体和科学应用的联系。

本讲介绍课程内容与生成模型的基本思路，后续课程展开推导和实践。



欢迎：希望大家学得开心，也学得扎实

首先欢迎各位同学选修这门课。希望一个学期以后，大家能理解大模型的工作原理，了解它的适用条件与局限。

我本人也是清华的数学博士。这门课会尽量从数学人熟悉的语言出发，把抽象概念与模型、代码和实验连接起来。

这是一个仍在快速发展的领域。我们可以一起推导、一起实验，也可以对同一个问题持有不同看法。

欢迎有依据的不同意见。你不需要因为与老师看法不同，而担心成绩。



从一次亲历的转折，开始这门课

2022 年前后：从研究模型到日常工具

我在微软研究院工作时，近距离感受了从 GPT-3.5 系列到 ChatGPT 的这一转折。此前主要出现在研究讨论中的能力，开始以对话的方式进入更多人的日常工作。

这段经历带来的问题

为什么一个统计学习系统，能够展现出超出单个训练任务直观描述的行为？这些行为可以怎样解释和验证？从专有模型到大模型。

这门课重点介绍大模型背后的**数学原理与研究方法**。

2022.11.30

ChatGPT 公开发布

原始版本基于 GPT-3.5 系列模型微调，并采用人类反馈强化学习等训练环节。



Math on AI: 用数学理解模型

把现象变成问题

从“模型生成得不好”，变成：目标函数不合适，还是采样过程有偏差？

现象 → 问题

把结构变成算法

用条件概率、变分原理与随机过程，理解模型到底在学习什么。

结构 → 算法

分析实验结果

推导之外，还要做对照、找反例、测误差，并记录计算代价。

结果 → 证据

数学帮助我们表述问题、构造算法和分析结果。



今天，我们沿着三个问题前进

01

**生成模型
在学什么？**

从一个数，到一个分布

02

**怎样从随机性
生成数据？**

概率结构与动力学

03

**怎样知道它
真的有效？**

代码、误差与计算成本

今天概览七类生成模型，并用双峰分布说明训练与采样的基本过程。详细推导将在后续课程展开。



苦涩的教训（1/13）

Rich Sutton 2019 年 3 月 13 日

从过去七十年的人工智能研究中，我们能够读出的最大教训是：那些能够利用计算规模的一般方法，最终才是最有效的方法，而且优势极其显著。其根本原因在于摩尔定律，或者更准确地说，是计算单位成本持续指数级下降这一更一般的趋势。大多数人工智能研究一直好像默认智能体可用的计算量是固定不变的；在这种假设下，利用人类知识几乎就成了提升性能的唯一办法。然而，只要时间尺度稍微拉长到超过一个典型研究项目的周期，就会不可避免地出现数量级更大的计算资源。



苦涩的教训 (2/13)

Rich Sutton 2019 年 3 月 13 日

研究者为了追求短期内可见的改进，往往试图利用自己对于领域的理解；但从长期来看，唯一真正重要的是对计算能力的利用。二者在原则上并不必然冲突，但在实践中却常常相互牵制。花在一种路线上的时间，就是没有花在另一种路线上的时间。研究者也会在心理上投入并固守某一种路线。更重要的是，基于人类知识的方法往往会把系统弄得更复杂，从而使其更不适合利用那些能够随计算规模扩展的一般方法。人工智能研究者迟迟才学会这一苦涩教训的例子有很多，回顾其中一些最突出的案例，是很有启发意义的。



苦涩的教训 (3/13)

Rich Sutton 2019 年 3 月 13 日

在计算机国际象棋中，1997 年击败世界冠军卡斯帕罗夫的方法，是建立在大规模、深度搜索之上的。当时，绝大多数计算机象棋研究者都长期致力于利用人类对国际象棋特殊结构的理解，因此他们对此感到失望。当一种更简单的、基于搜索的方法，借助专门的硬件和软件，证明远比那些方法有效时，这些依赖人类知识的象棋研究者并不是体面的失败者。他们说，“暴力”搜索这次也许赢了，但它不是一种通用策略，而且无论如何，这也不是人类下棋的方式。这些研究者希望基于人类输入的方法获胜，而当它们没有获胜时，他们感到失望。



苦涩的教训（4/13）

Rich Sutton 2019 年 3 月 13 日

类似的研究进展模式也出现在计算机围棋中，只不过又晚了二十年。早期大量努力都投入到了避免搜索上，研究者试图利用人类知识，或者利用围棋这一游戏的特殊性质；但一旦搜索被有效地、大规模地应用，这些努力就显得无关紧要，甚至适得其反。同样重要的是，通过自我对弈学习价值函数的方法；这一点在许多其他游戏中也很重要，在国际象棋中也如此，尽管学习在 1997 年首次击败世界冠军的程序中并没有发挥主要作用。自我对弈学习，以及更一般意义上的学习，和搜索一样，都是把海量计算资源真正用起来的途径。



苦涩的教训 (5/13)

Rich Sutton 2019 年 3 月 13 日

搜索和学习，是人工智能研究中利用大规模计算的两类最重要技术。在计算机围棋中，正如在计算机国际象棋中一样，研究者最初的努力都集中在利用人类理解上，也就是希望因此减少对搜索的依赖；而直到很久以后，当人们拥抱搜索和学习时，才取得了远大得多的成功。



苦涩的教训 (6/13)

Rich Sutton 2019 年 3 月 13 日

在语音识别中，20 世纪 70 年代曾有一场由 DARPA 赞助的早期竞赛。参赛者包括大量特殊方法，它们试图利用人类知识，例如关于词语、音素、人类发声器官等方面的知识。另一边则是一些较新的、更偏统计性质的方法，它们基于隐马尔可夫模型，使用了更多计算。结果再一次是，统计方法战胜了基于人类知识的方法。这引发了自然语言处理领域的一场重大转向：在随后几十年中，统计和计算逐渐主导了整个领域。近年来深度学习在语音识别中的兴起，只是这一持续方向上的最新一步。



苦涩的教训（7/13）

Rich Sutton 2019 年 3 月 13 日

深度学习方法更少依赖人类知识，使用更多计算，并在巨大训练集上学习，从而产生了性能显著更好的语音识别系统。就像在游戏领域一样，研究者总是试图构造一种按照他们认为自己的头脑工作方式来运行的系统——他们试图把这种知识放进系统里。但从长远来看，当摩尔定律带来了大规模计算能力，并且人们找到了利用这些计算能力的方法后，这种做法最终被证明是适得其反的，也是对研究者时间的巨大浪费。



苦涩的教训（8/13）

Rich Sutton 2019 年 3 月 13 日

在计算机视觉中，也出现了相似的模式。早期方法把视觉理解为寻找边缘，或者寻找广义圆柱体，或者使用 SIFT 特征。但如今，这些东西基本都被抛弃了。现代深度学习神经网络只使用卷积以及某些类型的不变性概念，却取得了远好得多的效果。



苦涩的教训 (9/13)

Rich Sutton 2019 年 3 月 13 日

这是一个重大的教训。作为一个领域，我们至今仍然没有彻底学会它，因为我们还在不断犯同一类错误。为了看清这一点，并有效抵抗这种倾向，我们必须理解这些错误为何如此有吸引力。我们必须学会这个苦涩的教训：把“我们以为自己如何思考”的方式内置到系统中，从长远来看是行不通的。



苦涩的教训（10/13）

Rich Sutton 2019 年 3 月 13 日

这个苦涩的教训基于如下历史观察：第一，人工智能研究者常常试图把知识直接构建进他们的智能体中；第二，这种做法在短期内总是有帮助的，而且会让研究者本人感到满足；第三，但从长期来看，它会达到平台期，甚至会阻碍进一步进步；第四，真正的突破最终来自相反的路线，也就是通过搜索和学习来扩展计算规模。最终的成功带着苦涩的意味，也常常没有被完全消化，因为这种成功是对一种备受偏爱的、以人为中心的方法的胜利。



苦涩的教训 (11/13)

Rich Sutton 2019 年 3 月 13 日

我们应当从这个苦涩教训中学到的一点，是通用方法的巨大力量；也就是说，那些即使在可用计算量已经变得极其巨大时，仍能随着计算增加而继续扩展的方法，才真正强大。看起来能够以这种方式近乎任意扩展的两类方法，就是搜索和学习。



苦涩的教训（12/13）

Rich Sutton 2019 年 3 月 13 日

我们还应当从这个苦涩教训中学到第二个普遍要点：心智的实际内容极其复杂，而且无可救药地复杂。我们应该停止试图寻找一些简单方式来描述心智内容，例如关于空间、物体、多个智能体或对称性的简单观念。所有这些，都是任意而内在复杂的外部世界的一部分。它们不应该被直接内置进系统，因为它们的复杂性没有尽头；相反，我们应该内置的，只是那些能够发现并捕捉这种任意复杂性的元方法。这些方法的关键在于，它们能够找到良好的近似；但寻找这些近似的过程，应该由我们的方法来完成，而不是由我们亲自完成。



苦涩的教训 (13/13)

Rich Sutton 2019 年 3 月 13 日

我们想要的是能够像我们一样发现的人工智能体，而不是只包含我们已经发现之物的人工智能体。把我们的发现直接内置进去，只会让我们更难看清发现过程本身究竟如何能够实现。



读完以后：把观点变成可以检验的问题

方法能否继续利用更多计算？

增加数据、训练或搜索预算后，误差怎样变化？性能提升是否达到平台？成本是否可承受？**我们设计的是答案，还是**

发现答案的方法？

哪些结构帮助学习，哪些规则把系统限制在已有经验里？能否通过对照区分二者？

课堂讨论：在相同预算下有效的方法，是否也最适合更大的预算？可以设计什么实验来比较？


怎样理解文中的强判断？

这是 Sutton 在 2019 年提出的历史论述与研究主张。具体任务仍须明确资源、数据与评价条件。**数学在这里做什么？**

定义目标、构造可扩展算法、分析误差，并设计能够推翻错误解释的实验。



一个小问题：最好的预测，为什么可能很不像数据？



数据来自两个峰

$$X \sim \frac{1}{2}\mathcal{N}(-2, 0.35^2) + \frac{1}{2}\mathcal{N}(2, 0.35^2).$$

如果只能输出一个数 a ，并最小化

$$\mathbb{E}[(X - a)^2],$$

最优解是 $a = 0$ ，却落在低密度区域。

课堂问题：这是平方损失“错了”，还是我们问错了问题？

本讲构造的合成分布；图中曲线由解析概率密度绘制。



点预测与分布学习，回答的是不同的问题

点预测：给我一个决定

$$a^*(c) = \arg \min_a \mathbb{E}[\ell(a, X) \mid c].$$

最优答案取决于损失。平方损失给条件均值，绝对值损失给条件中位数。
这很适合需要做单一决策的任务。

生成建模：给我可能性的结构

$$p_{\theta}(x \mid c) \approx p_{\text{data}}(x \mid c).$$

我们关心哪些结果可能出现、概率如何分配，以及怎样从中抽样。
同一个条件，可以对应多个合理答案。

生成模型不排斥预测。**学到分布之后，可以采样，也可以根据具体损失做决策。**



先把四件事分开：数据、模型、目标与采样

1 数据：我们观测到了什么？

$$\mathcal{D} = \{x^{(1)}, \dots, x^{(n)}\}, \quad x^{(i)} \sim p_{\text{data}}.$$

p_{data} 未知；有限数据、测量方式和数据筛选都会限制我们能学到什么。

2 模型：我们允许什么分布？

$$\{p_{\theta} : \theta \in \Theta\}.$$

分布可以通过密度、条件概率或随机生成过程来定义。

3 目标：怎样从数据学参数？

$$\theta^* \approx \arg \min_{\theta} \hat{\mathcal{L}}(\theta).$$

训练目标通常是可以估计、可以优化的代理目标。

4 采样：怎样生成样本？

$$\xi \sim p_{\text{base}}, \quad \hat{X} = S_{\theta}(\xi).$$

实际采样器可能只是理想模型的近似，额外误差由此出现。



最大似然：让数据在模型中“不那么意外”

$$\hat{\mathcal{L}}_{\text{NLL}}(\theta) = -\frac{1}{n} \sum_{i=1}^n \log p_{\theta}(x^{(i)}).$$

训练时：使用有限样本

提高观测样本的对数概率，同时依靠归一化、模型结构和优化过程约束概率怎样分配。

泛化性能需要在未见数据上评估。

总体上：匹配真实分布

在密度、支持集与可积性条件满足时，

$$\mathbb{E}_{p_{\text{data}}}[-\log p_{\theta}(X)]$$

不同模型采用不同的训练方法来拟合数据分布。



训练与生成：同一个模型，两种不同的计算过程

训练：已有数据，更新参数

$$\theta_{k+1} = \theta_k - \eta_k \widehat{\nabla}_{\theta} \mathcal{L}.$$

输入包括真实样本与训练时构造的随机量。通过反向传播改变网络参数。

问题：目标是什么？梯度怎样估计？能否稳定优化？

生成：参数固定，构造新样本

$$\xi \sim p_{\text{base}}, \quad X = S_{\theta}(\xi).$$

使用已训练网络，通过逐步预测、解码或求解动力学获得输出。

问题：随机性从哪里来？采样误差多大？需要调用几次网络？

训练更新参数，采样使用固定参数。 一次损失计算与完整的生成过程各有不同的计算成本。

不同的方法，训练和生成（推理）效率不同。



Transformer：网络结构，本质是复杂的解析函数



同一种网络架构，可以参数化不同的数学对象。一个网络输出的向量，只有放进**损失函数和采样过程**后，才获得明确的概率意义。

$$f_{\theta}(\text{输入}) \longrightarrow \begin{cases} \text{分类 logits,} \\ \text{后验均值 / 噪声预测,} \\ \text{速度场 / 转移率参数.} \end{cases}$$

架构背景：Vaswani et al., *Attention Is All You Need*, 2017。不同输出的具体意义取决于各模型定义。



七条路线：怎样把复杂分布变得可学习？

模型路线	核心构造	熟悉的数学连接
自回归	把联合概率拆成条件概率	概率链式法则、交叉熵
变分自编码器	引入隐变量与近似后验	条件概率、变分推断
生成对抗网络	通过生成器与判别器的博弈学习	极小极大优化、分布匹配
归一化流	用可逆变换搬运概率	变量代换、Jacobian
扩散模型	加噪后学习反向生成	随机过程、score、SDE
流匹配	学习随时间变化的速度场	ODE、连续性方程
离散扩散	在离散状态间构造跳转	马尔可夫链、转移矩阵

这些模型类有交集，同一生成过程也可以采用不同的训练方式。

路线对应的原始论文与导读见本讲参考文献页；本表按课程内容组织，模型类别之间可以重叠。



自回归：一个联合分布，分成很多条件分布

$$p_{\theta}(x_1, \dots, x_L) = \prod_{i=1}^L p_{\theta}(x_i \mid x_{<i}).$$

训练：观察完整序列

$$\mathcal{L}_{\text{AR}} = -\mathbb{E} \sum_i \log p_{\theta}(X_i \mid X_{<i}).$$

各位置的正确前缀已知；因果掩码控制每个位置可以使用哪些信息。

生成：逐步展开前缀

$$X_1 \sim p_{\theta}(\cdot), \quad X_i \sim p_{\theta}(\cdot \mid X_{<i}).$$


祖先采样按条件概率依次抽取；贪心解码则在每一步选择概率最大的项。两者产生的输出分布通常不同。

链式分解是恒等式； 实际能力与计算代价，还取决于条件模型、顺序和实现。



变分自编码器：用隐变量解释数据的变化

核心困难：对隐变量积分



$$p_\theta(x) = \int p_\theta(x | z)p(z) dz.$$

引入近似后验 $q_\phi(z | x)$ ，得到可优化的证据下界：

$$\log p_\theta(x) \geq \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x | z)] - \text{KL}(q_\phi(z | x) \| p(z)).$$

第一项让隐变量能解释数据，第二项约束近似后验与先验的偏离。

把“难算的边缘概率”，转化为**可采样估计的变分优化问题**。



生成对抗网络：通过判别任务学习生成分布

从简单噪声出发，生成器给出 $\hat{X} = G_{\theta}(Z)$ ；判别器 D_{ϕ} 尝试区分真实样本与生成样本。

$$\min_{\theta} \max_{\phi} \mathbb{E}_{X \sim p_{\text{data}}} [\log D_{\phi}(X)] + \mathbb{E}_{Z \sim p_Z} [\log(1 - D_{\phi}(G_{\theta}(Z)))].$$

通过样本训练生成器

判别任务提供训练信号；训练结束后，可以通过生成器一次前向计算生成样本。

难点转向博弈与覆盖

训练中需要检查稳定性、模式坍塌和多样性，并分别评估样本质量与分布覆盖。

GAN 通过判别器提供的训练信号学习生成分布，无需显式计算生成密度。

经典 GAN 的极小极大目标；后续 GAN 课程将讨论目标变体与训练方法。



归一化流：通过可逆变换，直接搬运概率

$$Z \sim p_Z, \quad X = g_\theta(Z), \quad z = g_\theta^{-1}(x).$$

$$\log p_\theta(x) = \log p_Z(z) - \log |\det Dg_\theta(z)|.$$

熟悉的数学：变量代换

局部体积被放大，概率密度就相应降低。
Jacobian 行列式记录这个体积变化。


新的计算问题：结构要能算

如何同时得到足够灵活的映射、可用的
逆映射，以及可承担的行列式计算？

这里讨论同维、可微、可逆的连续变换；**公式的条件也是模型设计的约束。**



扩散：先把数据变简单，再学习怎样回来



$$X_t = a_t X_0 + \sigma_t \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I).$$

$$\mathcal{L}_{\text{denoise}} = \mathbb{E}_{t, X_0, \varepsilon} \|\varepsilon_{\theta}(X_t, t) - \varepsilon\|^2.$$

这里展示一种常见的高斯扰动边缘分布和简化噪声预测损失。生成时还需要指定反向动力学、终端分布与数值采样器。

模型从数据中学习反向生成所需的统计信息，例如给定带噪状态的条件噪声均值。



流匹配：学习一个把噪声搬到数据的速度场

训练：先构造一条易采样的路径

取独立的 $Z \sim \mathcal{N}(0, I)$ 、 $X \sim p_{\text{data}}$,

$$X_t = (1 - t)Z + tX, \quad t \sim U[0, 1].$$

$$\mathcal{L}_{\text{FM}} = \mathbb{E} \|v_{\theta}(X_t, t) - (X - Z)\|^2.$$

训练只需采样端点和时刻，无需先求解整条 ODE。

生成：积分学到的速度场

$$\frac{d\hat{X}_t}{dt} = v_{\theta}(\hat{X}_t, t), \quad \hat{X}_0 \sim \mathcal{N}(0, I).$$


$\hat{X}_1$ 作为生成样本。

此页时间从**噪声端** 0 走向**数据端** 1，与上一页加噪方向不同。

确定性的 ODE 也能生成随机样本：**随机性来自初始条件**。理论成立还需要边缘速度场与适当的正则性。



离散扩散：没有连续位移，也可以有随机演化



离散状态之间的跳转

分类状态没有自然的大小顺序

对于 K 个类别，可以用随机替换定义加噪：

$$P_{\beta} = (1 - \beta)I + \beta \mathbf{1}\pi^{\top}, \quad 0 \leq \beta \leq 1.$$

π 是目标噪声分布。此处 $P_{\beta}(i, j)$ 表示从 i 到 j 的概率，行和为 1。

反向过程要学习：**如何去噪。**

离散扩散包括随机替换、mask 吸收态等转移结构；不同结构对应不同的建模与采样方式。



不同的损失，常常在学习不同的条件统计量

交叉熵：学习条件分布

若 X 是类别、 Y 是已知信息，则

$$\arg \min_{r(\cdot|Y)} \mathbb{E}[-\log r(X | Y)] = p(X | Y).$$

在无限表达能力的总体最优下，输出的是整个类别后验分布。

平方损失：学习条件均值

若 X 为数值向量，且二阶矩有限，则

$$\arg \min_f \mathbb{E}\|X - f(Y)\|^2 = \mathbb{E}[X | Y].$$

最优输出是条件均值，与条件分布采样通常有不同的结果。

损失函数的含义取决于条件信息与预测对象。有限网络和有限训练还会带来逼近误差。



为什么一个“均值预测器”，还能用于生成？

条件均值与 score 的关系

设 $Y = X + \sigma\varepsilon$, $\varepsilon \sim \mathcal{N}(0, I)$, $\sigma > 0$ 。

$$m(y) = \mathbb{E}[X \mid Y = y],$$

$$\nabla_y \log p_Y(y) = \frac{m(y) - y}{\sigma^2}.$$

左边：score

带噪分布的对数密度梯度，告诉我们概率密度在局部怎样变化。

右边：去噪残差

平方损失学习的后验均值，在高斯扰动下可以转化为同一个局部信息。

随噪声尺度变化的条件均值函数提供反向生成所需的信息，生成样本还需相应的动力学与采样器。



把刚才的双峰分布，变成一个可训练的生成器

训练：拟合条件速度

```
# x: target samples; z: Gaussian noise
z = torch.randn_like(x)
t = torch.rand_like(x)
xt = (1 - t) * z + t * x
loss = ((v_theta(xt, t) - (x - z))**2).mean()
optimizer.zero_grad()
loss.backward()
optimizer.step()
```

生成：用 Euler 法走到数据端

```
x = torch.randn(n, 1)
for k in range(K):
    t = torch.full_like(x, k / K)
    x = x + v_theta(x, t) / K
```

网络输入是 (x, t) ，输出一个速度。参数固定后，从新的初始噪声生成新样本。

训练时拟合条件速度，生成时用 Euler 法积分。课后可补齐网络定义、数据生成与训练循环，比较不同采样步数的结果。

实现时应固定随机种子，记录配置，并在采样阶段使用 `eval()` 与 `no_grad()`。



正确的速度场，也可能被过粗的数值步长破坏

回到均值为零的双峰分布

取独立的 $Z \sim \mathcal{N}(0, 1)$ 、 $X \sim p_{\text{data}}$ ，令 $X_t = (1 - t)Z + tX$ 。平方损失的总体最优速度为

$$v^*(x, t) = \mathbb{E}[X - Z \mid X_t = x].$$

在初始时刻， $X_0 = Z$ ，所以

$$v^*(z, 0) = \mathbb{E}[X] - z = -z.$$

若只做一步步长为 1 的 Euler 积分，

$$\hat{X}_1 = Z + v^*(Z, 0) = 0.$$

所有样本都落到均值。即使初始速度完全正确，过粗的积分仍会破坏生成分布。

独立耦合、对称双峰目标下的解析计算。



怎样设计一个能解释误差的对照实验？

固定模型，改变采样

固定网络参数和同一批初始噪声，比较不同 Euler 步数；记录网络调用次数、耗时以及生成分布。一维等样本量时，可计算经验距离：

$$\widehat{W}_1 = \frac{1}{n} \sum_{i=1}^n |x_{(i)} - y_{(i)}|.$$

排序下标表示经验分位数配对；目标参考样本应独立生成。

误差来自不同环节

数据与模型假设、有限网络表达、优化过程、数值积分，以及有限样本评估都会影响结果。

加步数能解决什么？

可以减少一部分积分误差，但不会自动修复学错的速度场，也不保证测得的误差严格单调下降。

Euler 与 Heun 的一步通常对应不同的网络调用次数，比较时应同时报告 NFE 与实际耗时。



为什么理解大模型，也必须理解计算？

计算量

一次网络调用做多少运算？
训练需要多少次更新？生成需要多少次调用？

关注矩阵运算、批处理与采样步数。

存储与数据移动

参数、梯度、优化器状态和激活占多少空间？数据能否及时送到计算设备？

关注显存、精度与实际吞吐。

依赖与并行

哪些计算可以一起做？哪些步骤必须等待前面的结果？并行本身有什么开销？

分析算法依赖与并行开销。

$$\text{生成耗时} \approx \underbrace{\text{网络调用次数}}_{\text{算法选择}} \times \underbrace{\text{每次调用耗时}}_{\text{模型、批量与实现}} + \text{其他开销}.$$

我们关心的是：**一个数学上的好想法，怎样变成计算上可实现、可测量的算法。**



实验比较：指标、预算与复现

先决定要比较什么

相同生成质量下，谁更快？相同训练预算下，谁更准？相同硬件与批量下，谁的吞吐更高？

这些是不同问题，不能用一个没有条件的“更强”代替。

再说明结论怎样得到

固定数据划分与评估协议，记录参数量、训练量、采样设置、设备和随机种子；对关键结论重复实验并做对照。

记录 loss 的变化，并通过重复实验检查结果是否稳定。

分别报告网络调用次数、耗时、参数量、计算量和任务指标，并说明测量方法与比较范围。



多模态：联合分布与条件生成

在建模层面，看两类常见状态

离散变量 D ：文字、元素类别、符号序列。

连续变量 C ：图像强度、坐标、波形、测量数值。

实际系统还需要处理各模态的表示、结构与量化。

从联合分布到不同任务

$$p_{\theta}(D, C), \quad p_{\theta}(C \mid D), \quad p_{\theta}(D \mid C).$$

同一对象的符号描述与连续观测，能否互相约束？模型能否在不同条件下生成、补全和理解？

联合概率分解给出建模起点；共享表示的质量取决于训练目标、生成过程及两类变量之间的信息利用。



科学智能：从“生成一个样本”到“满足一个问题”

分子与材料设计

$$p_{\theta}(D, R \mid c).$$

D 表示组分类别, R 表示坐标, c 可以是设计条件。
要检查结构合理性、对称性, 以及性质验证是否支持设计目标。

逆问题与科学计算

$$y = \mathcal{A}(x) + \eta.$$

给定不完整、有噪声的观测, 恢复可能的状态或参数。
结果需要与观测和误差模型一致。

物理系统建模

$$p_{\theta}(x_{0:T} \mid c).$$

建模轨迹、边界条件或控制条件下的状态变化。
评估单步预测、长期行为、稳定性与适用范围。

模型给出候选解释, 再通过观测、计算检验或真实实验验证。

代表性实例: Hoogeboom et al., [Equivariant Diffusion for Molecule Generation in 3D](#), ICML 2022; Song et al., 2021 的逆问题示例。



世界模型：预测行动的后果

$$Z_t = E_{\theta}(O_{\leq t}, A_{< t}), \quad Z_{t+1} \sim p_{\theta}(\cdot \mid Z_t, A_t), \quad O_{t+1} \sim p_{\theta}(\cdot \mid Z_{t+1}).$$

表示与生成

编码观测，学习状态转移，再预测或生成未来观测；生成模型提供其中的分布建模工具。

规划与验证

比较不同动作序列的预测后果，再选择行动；还要验证行动一致性、长期误差与真实任务表现。

规划能力需要通过行动响应和长期预测来评估，同时检查误差随时间的累积。



强化学习、推理与智能体：把学习和搜索接起来

强化学习

学习策略与价值，通过交互反馈优化长期回报：

$$\max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^T \gamma^t R_t \right].$$

生成得像数据，与行动后获得高回报，是不同目标。

推理与搜索

生成候选步骤，评估中间结果，必要时搜索、回溯或修正。更多计算能否带来更好答案，取决于搜索空间、反馈与验证机制。

智能体系统

把模型与工具、记忆、环境和反馈连接成闭环。除输出质量，还要衡量任务成功率、调用成本和失败后的恢复能力。

呼应《苦涩的教训》：**学习改变模型，搜索利用模型探索可能性。**怎样有效使用计算，是二者共同的问题。



一个学期的主线：原理、算法、实践与应用

阶段	核心内容	希望获得的能力
建立语言	概率建模、神经网络与优化；训练与采样；基本计算概念	读懂模型定义与目标
理解构造	自回归、VAE、GAN、归一化流、扩散、流匹配、离散扩散	推导关键关系、比较方法
亲手训练	小规模模型、数值采样、误差诊断、效率测量与复现	从头实现并解释结果
走向问题	多模态、世界模型、强化学习、推理、智能体与科学应用	提出问题、设计验证

模块之间会相互穿插：**看到数学，就尽量找到算法；看到实验，就继续追问它的数学含义。**

课程内容会结合实践进展穿插展开；世界模型、强化学习、推理、智能体与科学应用贯穿后续课程。



进入这门课，需要哪些准备？

数学基础

微积分、线性代数与基本概率；熟悉条件概率、期望、梯度与矩阵运算，会更容易进入课程。

计算基础

能够阅读和修改 Python；逐步熟悉张量、自动微分、训练循环和最基本的调试。

更重要的习惯

遇到概念先问定义，遇到结论先看条件，遇到结果先想如何验证。

GPT 时代的学习，已经从金字塔形变成了柱形学习。



鼓励使用 AI，但把验证能力留在自己手里

让 AI 帮你推进工作

解释陌生概念，提供不同推导思路；搭建代码、设计测试、寻找可能的反例，并帮助整理实验记录。

核对推导和假设

检查所用假设、容易出错的步骤，并用简单例子检验结论。

你需要能够说明与复核

符号和条件是否一致，引用能否找到，代码是否真的运行，结果是否来自所报告的设置。

让协作过程可说明

记录 AI 提供的关键帮助、你修改的地方，以及你怎样验证最后的结论。

两次课堂小作业不能使用大模型。日常学习中可以借助 AI，提交的推导与代码需要自己理解并核验。



课程希望培养的能力

能解释

说清模型学习的对象、目标函数的含义，以及关键推导成立的条件。

能实现

把公式转为代码，记录设置，复现结果，并定位实验与预期不一致的原因。

能判断

提出有意义的比较，寻找反例，区分已证实、暂时支持与仍然未知的结论。

分析失败实验、复核已有结论，都能帮助我们加深理解。

大模型时代，理解和验证能力是一种强能力。



考核方式：平时成绩与课程大作业各占一半

50% 平时成绩

- ▶ 几次课后作业。
- ▶ 两次课堂小作业。

课堂小作业不能使用大模型。

题目比较简单，主要考查对课程概念与基本原理的理解。

50% 课程大作业

课程大作业占总评成绩的一半。

总评成绩 = 50% 平时成绩 + 50% 课程大作业。



阅读建议：扩散与流匹配

看懂一次“从噪声到数据”的完整过程

Ho, Jain & Abbeel. *Denoising Diffusion Probabilistic Models* (2020).

先找：前向怎样加噪？网络预测什么？训练算法与生成算法有什么不同？

把回归损失与微分方程连起来

Lipman et al. *Flow Matching for Generative Modeling* (2022/2023).

先找：为什么能构造速度标签？训练用的条件路径与生成轨迹是什么关系？

数学背景暂时不够时：用讲义搭桥

Peter Holderrieth & Ezra Erives. *An Introduction to Flow Matching and Diffusion Models*.

先补概率路径、向量场与采样之间的联系，再回到原始论文核对。

DDPM 原文 | Flow Matching 原文 | MIT 课程讲义与代码。扩展文献见附录。



下课前，留下三个问题

为什么最优的均方误差预测，不一定是好的生成样本？

它给出了条件均值，而生成任务关心整个分布及其采样。

确定性的 ODE，为什么仍然可以生成随机样本？

随机初始条件经确定性流映射，形成新的概率分布。

一个模型表现不好，我们应该先怀疑哪里？

先区分数据与假设、模型表达与训练目标、优化与数值采样，再设计能区分原因的实验。

知其然，知其所以然； 再亲手让它发生。

期待和大家一起，在问题、推导与实验中前进。



附录 A1 最大似然与 KL：在哪个层面等价？

先在总体分布上推导

令 p 与 q 是同一参考测度下的密度，并满足所需支持与可积性条件。

$$\begin{aligned}\mathbb{E}_p[-\log q(X)] &= - \int p(x) \log q(x) \, d\mu(x) \\ &= - \int p(x) \log p(x) \, d\mu(x) + \int p(x) \log \frac{p(x)}{q(x)} \, d\mu(x) \\ &= H(p) + \text{KL}(p\|q).\end{aligned}$$

离散情形用计数测度，连续情形可用 Lebesgue 测度。对 $q = p_\theta$ ，熵项不依赖 θ 。

经验 NLL 是总体期望的样本估计。 有限经验点质量与连续密度未必满足绝对连续条件，因而上述密度 KL 恒等式可能不适用。



附录 A2 平方损失为什么给出条件均值？

设 $m(Y) = \mathbb{E}[X | Y]$, $X \in L^2$ 。对任意平方可积的 $f(Y)$,

$$\begin{aligned}\mathbb{E}\|X - f(Y)\|^2 &= \mathbb{E}\|X - m(Y)\|^2 + \mathbb{E}\|m(Y) - f(Y)\|^2 \\ &\quad + 2\mathbb{E}\langle X - m(Y), m(Y) - f(Y) \rangle.\end{aligned}$$

交叉项为零，因为

$$\mathbb{E}[X - m(Y) | Y] = 0.$$

于是得到正交分解：

$$\boxed{\mathbb{E}\|X - f(Y)\|^2 = \mathbb{E}\|X - m(Y)\|^2 + \mathbb{E}\|m(Y) - f(Y)\|^2}.$$

不可约的条件方差，加上预测器偏离条件均值的误差。这既解释了点预测，也解释了去噪与流匹配的总体最优目标。



附录 A3 训练的直线，为什么对应一个生成流？

定义 $X_t = (1 - t)Z + tX$ ，以及边缘速度场

$$v^*(x, t) = \mathbb{E}[X - Z \mid X_t = x].$$

对光滑紧支撑测试函数 φ ，在可交换求导与期望的条件下，

$$\begin{aligned}\frac{d}{dt}\mathbb{E}[\varphi(X_t)] &= \mathbb{E}[\nabla\varphi(X_t) \cdot (X - Z)] \\ &= \mathbb{E}[\nabla\varphi(X_t) \cdot v^*(X_t, t)].\end{aligned}$$

这正是连续性方程的弱形式：

$$\partial_t p_t + \nabla \cdot (p_t v^*) = 0.$$

在适当的存在唯一性条件下，ODE 流具有这组边缘分布。训练端点的直线与生成轨迹可以不同，但具有相同的边缘概率演化。



附录 A4 反向生成：连续与离散的并排观察

令 s 为反向时钟, $t = T - s$, $Y_s = X_t$; p_t 为前向分布。

连续：反向漂移包含 score

前向 SDE (g 只依赖时间):

$$dX_t = f(X_t, t) dt + g(t) dW_t.$$

在适当正则性条件下, 反向过程为

$$dY_s = b_s(Y_s) ds + g(t) d\bar{W}_s,$$

其中

$$b_s(y) = -f(y, t) + g(t)^2 \nabla \log p_t(y).$$

离散：反向速率包含概率比

前向行生成矩阵 Q_t 满足

$$q_t(i, j) \geq 0 \ (i \neq j), \quad \sum_j q_t(i, j) = 0.$$

若 $p_t(i) > 0$, 反向非对角速率为

$$\bar{q}_s(i, j) = q_t(j, i) \frac{p_t(j)}{p_t(i)}.$$

对角项由行和为零确定。使用列概率向量时, 前向方程为 $\partial_t p_t = Q_t^\top p_t$ 。

共同结构：已知的前向机制，加上当前分布的信息，决定反向演化。

连续反向 SDE 参见 Song et al., 2021; 离散反向速率由 Bayes 公式与短时转移概率展开得到。



附录 A5 注意力机制：一次带数据依赖权重的混合

给定表示矩阵 $H \in \mathbb{R}^{L \times d}$ ，令

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V,$$

其中 $Q, K \in \mathbb{R}^{L \times d_k}$ 、 $V \in \mathbb{R}^{L \times d_v}$ 。单头注意力为

$$\text{Attention}(Q, K, V) = \text{softmax}_{\text{row}} \left(\frac{QK^\top}{\sqrt{d_k}} + M \right) V.$$

表示的相互作用

$QK^\top$ 产生位置之间的匹配分数；按行 softmax 后，对 V 做数据依赖的加权混合。

信息边界由掩码控制

因果掩码对未来位置置 $-\infty$ ；其他任务可用其他掩码。掩码约束可见信息，不自定义整个生成模型。



参考文献 I 概率构造与模型基础

[1] OpenAI. *Introducing ChatGPT*. November 30, 2022.

用于开课历史背景；不作为模型全部能力的证明。

[2] Vaswani, A., et al. *Attention Is All You Need*. NeurIPS, 2017.

Transformer 与注意力架构。

[3] Kingma, D. P., and Welling, M. *Auto-Encoding Variational Bayes*. arXiv 2013; ICLR, 2014.

隐变量模型、变分下界与重参数化。

[4] Rezende, D. J., and Mohamed, S. *Variational Inference with Normalizing Flows*. ICML, 2015.

以可逆变换构造更灵活的分布。

[5] Ho, J., Jain, A., and Abbeel, P. *Denoising Diffusion Probabilistic Models*. NeurIPS, 2020.

扩散模型的代表性训练与采样框架。



参考文献 II 动力学、离散状态与科学应用

- [6] Song, Y., et al. *Score-Based Generative Modeling through Stochastic Differential Equations*. ICLR, 2021.
- [7] Lipman, Y., et al. *Flow Matching for Generative Modeling*. arXiv 2022; ICLR, 2023.
- [8] Austin, J., et al. *Structured Denoising Diffusion Models in Discrete State-Spaces*. NeurIPS, 2021.
- [9] Hoogeboom, E., Satorras, V. G., Vignac, C., and Welling, M. *Equivariant Diffusion for Molecule Generation in 3D*. ICML, 2022.
- [10] Holderrieth, P., and Erives, E. *An Introduction to Flow Matching and Diffusion Models*. MIT course notes, 2025.

阅读时核对公式的定义、结论的条件和实验设置，并查阅所引用的原始来源。

